拾象科技
SHIXIANG TECH

How to Play AI Beta？

拾象 AGI 洞察 2025 Volx

Dec 2025

Part 01

AI 关键判断

拾 象 科 技
SHIXIANG TECH

AI 关键判断 Highlights

- 模型交替领先是常态
- Google + OpenAI = $10T
- 2026 年能看到下一代新范式
- AGI 竞赛是马拉松，是现金流持久战
- AI 要面对的关键问题：经济价值到底有多大？
- AGI 投资策略：只 bet 技术成长最陡峭的地方

判断 1：AI Labs 交替领先会成为模型竞争常态

格局变化

- 全球 Top 3 没变：GPT / Claude / Gemini
- 基础模型拿走大头，头部 3 家的溢价最大：～90% of Total AI Rev.
- 现有范式下，拼的是战略 bet 选择 和组织执行力

	技术路线分化	算力阵营
Google	多模态断档式领先	**TPU** Google自成一体，首次推出 SOTA
OpenAI	ChatGPT消费端用户体验依然最佳	**GPU** NV支持 OpenAI，Anthropic 依然会拿出看家本领
ANTHROP\C	Claude Code 依然是 Coding 领域的SOTA	

判断 2：Google + OpenAI = $10T

市场Concern **Gemini 崛起，NVDA + OpenAI 链怎么办？**

Our Answers：

- AI 不是零和博弈：Google 不会一家独大，而是 Google 和 OpenAI 共同把 AI 盘子做大
  - Why OpenAI：全球最好的 AI 标的 / 对下一代范式的探索 /
  - Why Google：全栈式 AI 资源，“最领先的追随者”
- 长期理想愿景：
  - Google + OpenAI 市值愿景 $10T，
  - 无论是 DAU 角度还是市场份额角度，ChatGPT : Gemini ≈ 5 : 1

判断 3：2026 年会看到下一个范式信号

Pre-training Scaling 快结束了，但 Online Learning 才刚刚开始

- **Where Are We Now?**
  - Pre-training 80%，RL 30%-50% ———— > Data scaling 仍在继续
  - Pre-training 有空间，但 Pre training 确实搞不出更多数据了
- 机器人、世界模型、多模态…也许并不构成范式级别的问题，Continual Learning 可能才是唯一重要的真问题
- Continual Learning 的成熟也需要基础设施支持

判断 4：AGI 竞赛是“马拉松+自动驾驶”：持久战和现金流之战

■ **“自动驾驶”视角：**

- Agent 要处理的长尾数据量很大，解决长尾问题需要的时间比较久
- 可以局部 L3/L4，但整体 L4 是极难攀登的高山

■ **AGI 战是持久战，是现金流之战**

- OpenAI：$1.4T CapEx “绑架”美股
- Meta 人才竞争
- Google / ByteDance 自身主业有充分的现金流支持探索 AGI

判断 5：AI 必须回答商业模式和效率质疑

- Why：只靠订阅、广告和电商赚不回 $1.4T，
- How：
  - Option 1: 需要 Agent 真正实现端到端替代劳动力，赚取企业的智力劳动预算
  - Option 2: AI 做人做不了的增量高价值内容，真正实现价值增量

e.g：

Coding Agents 重写cuda，

Scientific Agents 治愈人类所有疾病

可靠性是卡点，

需要 Continual Learning 本质上的突破

Sam Altman @sama · Nov 7

I would like to clarify a few things.

……

First, “How is OpenAI going to pay for all this infrastructure it is signing up for?” We expect to end this year above $20 billion in annualized revenue run rate and grow to hundreds of billion by 2030. We are looking at commitments of about $1.4 trillion over the next 8 years. Obviously this requires continued revenue growth, and each doubling is a lot of work! But we are feeling good about our prospects there; we are quite excited about our upcoming enterprise offering for example, and there are categories like new consumer devices and robotics that we also expect to be very significant. But there are also new categories we have a hard time putting specifics on like AI that can do scientific discovery, which we will touch on later.

判断 6：AGI 投资策略：只 bet 技术成长最陡峭的地方

关键词：围绕主线，关注 AI Labs 和平台进化趋势

- 投资全球最领先的 2-3 家模型公司
- 投资最领先模型需要的算力和硅基 Infra
- 投资最领先模型技术溢出的红利
- 围绕关键平台寻找机遇：ChatGPT / Google / Gemini / ByteDance

今天要 bet 3 年后的范式和 Potential Winners

Ideal AGI Basket

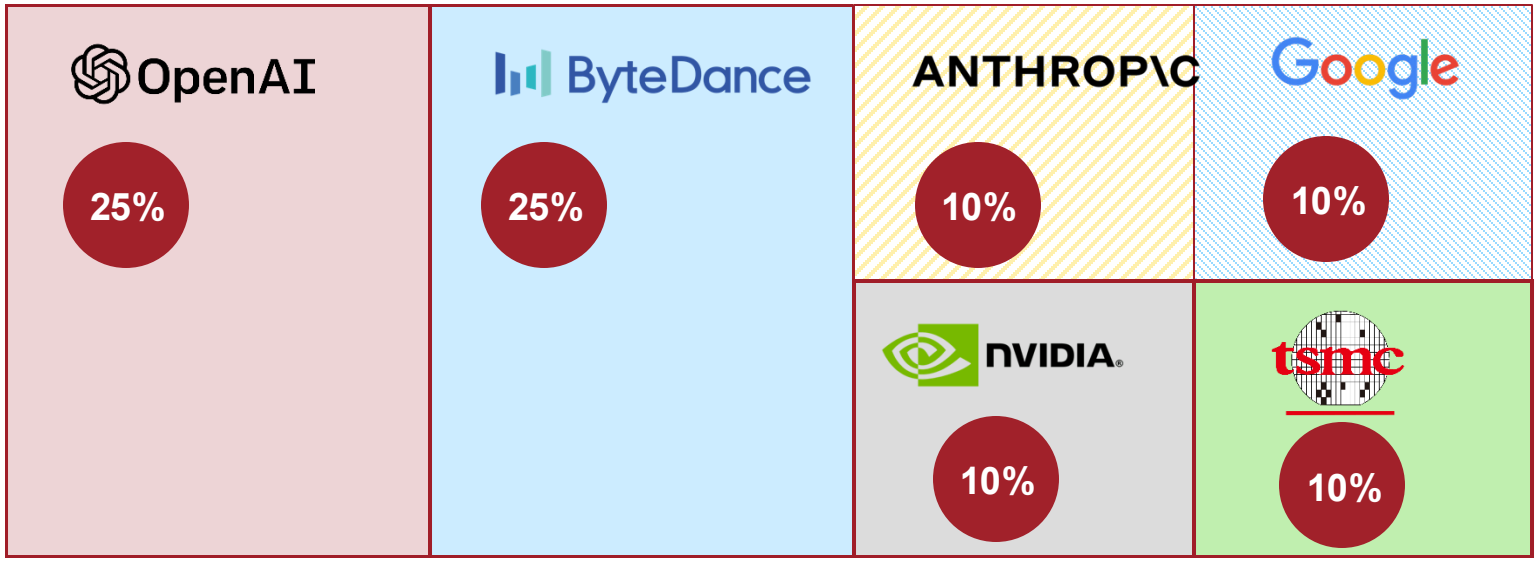

判断 7：2026 AI 投资主题

- 看见下一代范式：Online learning
- 多模态大年
- AI Knowledge Worker
- Proactive Agents

豆包手机：Agent 会“吃掉”谁？

- 超级流量入口：Super App、Google Search
- 手机厂商

Agent 会是 AI 时代流量大战的起点吗？

Part 02

湾区重要趋势

拾象科技
SHIXIANG TECH

1# 模型即产品，数据即模型

Sora, Gemini3 再次说明模型即产品，体验的明显升级来自模型进步

Sora2

注重 meme 和传播性

Nano Banana Pro

图片编辑，制作 slides
碾压 PPT 创业公司

Veo3 AI

注重 creator 体验

Gemini 3

前端生成效果优于 Claude Code，后端效果不如 Claude Code 和 CodeX

Sora，Veo 的可玩性远超可灵&即梦，说明模型换代比工程优化更重要

模型训练方向前所未有地分化；AGI，SOTA 模型的叙事不再重要，重要的是差异化上的 SOTA

Gemini： 多模态 Assitant

Claude Code： Coding Agent

ChatGPT： 聊天朋友和 Assistant

Thinking Machines Lab： 个性化 Agent，新交互

模型仍在进步，但进步来自对人类未留痕数据的缓慢蒸馏

Pre-train data	RL 专家数据	Self improvement / Continual learning
石油 量大但快用完了	新能源 有用但慢	核聚变 还没突破，突破就无敌

MERCOR

surge AI

Handshake

2# 2026 年是多模态大年，机器人是多模态和世界模型的重要 interface

公司	近三个月核心发布	技术路线	差异化
Physical Intelligence (π)	• π*0.6 VLA • Recap RL	VLA 结合 offline/online RL，通过 advantage-conditioning 提升策略质量	在真实世界 RL 做到 10h+ 稳定执行
sunday	• Memo 家用轮式人形 • ACT-1	手套众包收集1000万条数据，家庭场景模型	大规模低成本家庭数据，聚焦C 端家务场景
Generalist	• GEN-0 Embodied Foundation Model	以实体交互数据为主的 VLA，强调embodied scaling law	实体世界“大模型 + scaling law”叙事，数据量级最大之一
DYNA	• DYNA-1 商业部署 • 24h 叠衣服/纸巾实验	Foundation model + reward model RL，自主学习	面向 B2B 场景的高可靠自治，客户部署反馈闭环
Google	• Gemini Robotics 1.5 Cross-Embodiment	通用多模态 LLM 下沉到机器人，跨机体迁移	借 Gemini 生态和算力做 cross-embodiment，大厂级规模优势
1X	• NEO 家用人形机器人开启预订	Redwood AI 模型 + Expert Mode 远程人类兜底	首个明确定价的 C 端人形机器人
sharpa	• SharpaWave 灵巧手量产 获得CES 奖	高 DOF 灵巧手 + 高分辨触觉	SOTA 灵巧手，拥有 22 个自由度，美国M7客户

2# 2026 年是多模态大年，机器人是多模态和世界模型的重要 Interface

数据是最重要的 bet

Generalist

27 万条真实机器人交互数据，
称发现了 scaling law

sunday

改造 Umi，实现用手套低成本
收集千万条众包家庭数据

Physical Intelligence (π)

每周更新数据收集 Pipeline，在真
实 Airbnb环境内持续收集数据

世界模型和 YouTube 数据也即将成为重要来源

- **RL 在机器人中的作用比在 LLM 中更显著**
  - Pi 发布的 RECAP 策略：机器人能通过 value function 和 credit assignment，从成功和失败的轨迹中不断提高 performance
- **机器人在湾区开始出现商业化落地场景**
  - Dyna 为2B商家提供叠衣服，叠纸巾等服务，robust 得到验证
- **硬件重要性在凸显**
  - 特斯拉，1x，figure 等是硬件代表，Pi 也开始涉足硬件
- **和 LLM 先统一再分化不同，机器人一上来就分化**
  - 原因是没有统一的 pre training 基础，也没有统一的硬件
  - 多模态进步和人才的涌入让有能力的团队都可以有自己的bet

3 # Proactive Agent 会成为胜负手

模型能力拓展的 横向 和 纵向

- 横向蒸馏人类知识：Post training 和 RL 带来的 domain knowledge 拓展，横向覆盖更多行业领域
- 纵向探索下一个技术范式：模型记忆提升，更了解用户，更主动，创造更高经济价值，成为 Proactive Agent

■ Proactive (learning) Agent 为什么重要？新技术范式 / 用户粘性 / 真正的个性化

OpenAI Mark Chen 对未来 ChatGPT 的构想本质上就是一个Proactive Agent：

1. Memory 会被大幅升级
2. 从用户问答交互中从深层次学习、理解用户
3. “提前准备”和用户有关的新问题、信息
4. 需要新的硬件和交互承载

■ Proactive Agent 的形态：

- **意图识别：** Agent 可以在合适的时间 take actions
- **Always-on：** 了解用户的 context
- **长期记忆：** 了解用户的长期目标和偏好，在合适的时间主动行动
- E.g：OpenAI Pulse，Thinking Machine Labs

4 # Neo AI Labs

Neo AI labs 的机会是什么？

- OpenAI 和 Deepmind Mafia，头部人才流动
- 全新的技术路线
- 开源
- 头部 Lab 想要但没精力做的领域

主要 Neo Labs 公司基本情况

公司	创始团队	核心目标	差异化
Isara	Eddie Zhang（前 OpenAI safety）等	Multi-agent Digital Society	重点是大规模 agent 编排和治理基础设施
Humans&	Eric Zelikman （前 xAI，早期 Googler，Stanford PhD）	有 EQ 的模型	主打理解人类情绪、价值权衡和长期关系，人本交互（Human-centric AI）。
Periodic Labs	Liam Fedus（ChatGPT 核心，exGoogle） Ekin D. Cubuk（前 DeepMind/Google）	材料 / 科学大模型， 「AI 科学家」闭环	专注材料与物理实验数据而非互联网文本
General Intuition	Pim de Witte（Medal 创始人，CEO） 以及其他 Medal 核心	具有强空间–时序推理的 World Models	用 Medal 每年约数十亿段游戏视频片段训训练，先解 3D 游戏 / 运动，再外溢到无人机、机器人等 embodied AI。
Reflection AI	Misha Laskin（Gemini 奖励建模负责人） Ioannis Antonoglou（AlphaGo 共同作者）	美国版 DeepSeek	做 Open Frontier LLM，放权重不放数据/管线；RL + LLM 做自主编码起步，定位美国开源/开放前沿实验室，对标 DeepSeek、OpenAI、Anthropic。
SSI	Ilya Sutskever Daniel Gross（前 Apple AI 负责人） Daniel Levy（前 OpenAI 研究员）	唯一产品目标：安全的超级智能	不做短期商业产品，「straight-shot SSI lab」。Ilya 公开强调“单纯 scale 已到头”，要做超越 next-token 的新范式，但技术细节基本未披露。

5# Voice Agent 是新一代 OS 的入口

行业范式转移和护城河

1 模型层正在发生根本性变化

听 STT → 想 LLM → 说TTS

Real-time Speech-to-Speech
End-to-end STS

更快反应　更强情绪　更自然打断

2 延迟只是入场券

企业真正买单的是
稳定性 + 全套上线体系

ElevenLabs 如何赢得企业市场？

多模型级联 fallback ✚ Versioning / Monitoring

3 路线分化

极致速度 Sonic-3 超低延迟

Cartesia

极致真实感 拟人化对话

4 RTC 基建变成护城河

模型再快也需要全球实时网络
（like Tencent TRTC）

Why Voice = 下一个入口层?

最符合人类直觉的交互

“开口即达”交互零摩擦
远胜 App/Web 点击

高频低认知任务首选

速度极快，零学习成本，
极大提升效率

跨设备 OS 层入口

随时在线，渗透各类
智能终端与 IoT

Voice Agent 已经超越了 SaaS 工具范畴，正在成为定义下一代计算平台的 OS 级入口层

5 # Voice Agent Infra：把电话线托管成一套“语音操作系统”

Infra = 电话线操作系统（Voice OS）企业不需要懂模型，只要接线即可运行 AI

核心模块

语音路由
SIP/WebRTC

打断策略
barge-in / turn-taking

模型编排
STT/LLM/TTS 组合管理

监控 & Failover
跨平台容灾

为什么 Vapi / Retell 会成为行业标配

项目	Vapi	Retell
核心卖点	快速搭建 / 多场景	更稳 / 更低延迟
适用客户	多元 SME	高并发 + 高要求场景
特点	易用性强	在相同模型组合下更稳
商业性	PLG 强	企业级收入（ARR ~36M）

开源方案不是替代，而是“可定制补充”

LiveKit
- 音视频 RTC，医疗大量采用

Pipecat
- 可编排、自由接模型

Infra 层不是卖分钟，而是把电话线托管成一套“语音操作系统”

部署路径

- BYO SIP
  - Bring Your Own SIP 无缝集成现有通信线路
  - 支持自带运营商线路，无需更换号码，即插即用
- Vapi/Retell调度层
  - 智能对话操作系统 (Voice OS)
  - 毫秒级响应，统筹听、想、说，精准处理插话与打断
- 自选模型
  - 灵活的模型组合策略
  - 自由组合最佳 LLM，适配不同场景。
- CRM/EHR
  - 深度业务数据互通， 打通 CRM/EHR 系统
  - 实时读写客户档案，让 AI 具备“记忆”与“办事”能力
- 人工接管
  - 完善的人工兜底机制
  - 杂场景或情绪预警时，平滑转接人工座席，保障服务质量

5 # Voice Agent：从客服到“高频低认知任务”的入口

高频入口

Inbound / 餐饮 / 客服

- 100% 接听、不排队
- AI 自动下单

成本砍半

漏接率下降80%+

最先跑通PMF的场景

结果导向

Outbound / Sales / Collections

- AI 扛并发，人做转化
- 贷款、保险、催收成熟

回款提升 20-30%

AI 负责筛选人类专注转化

高价值场景

医疗挂号 / 分诊 / 医疗接线

- 零漏接、快速分级
- 自动记录、合规

等待时间下降50%

弃号 ↓80%+

医疗是 ROI 最夸张赛道

新入口

智能眼镜 / 穿戴式设备

- 智能眼镜的 OS 层
- 自然对话 = 操作系统

ROI 核心指标框架

Containment（拦截率）
能挡 60-90% 的来电

满意度提升
不会情绪化、更耐心

成本
$0.07-0.30 / min vs 人工

AHT 下降
对话更快、效率更高

Voice 是所有 Agent 中最早跑通“真正 ROI”的方向

6 # ChatGPT vs Gemini数据洞察：模型格局

Highlights 1 **Gemini 3 发布改变模型格局了吗？**

- 对模型格局产生了竞争，但反映产品在增速上 DAU 增长 15-20% 不如 Nano Banana
- ChatGPT 在 web 生产力端受到了一定的冲击，但在生活助手 Mobile 层面还相对稳健

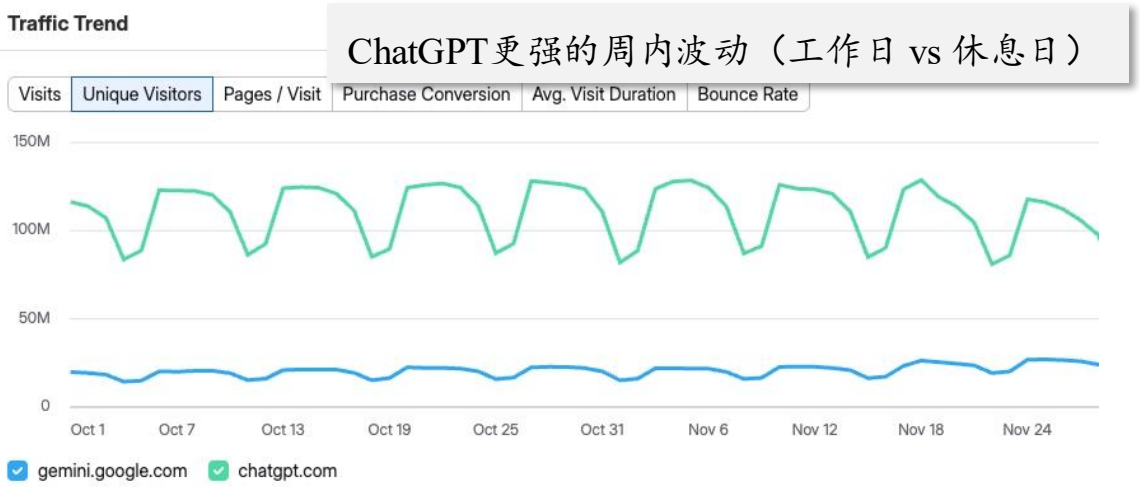

source: semrush

6# ChatGPT vs Gemini 数据洞察

Highlights 2

流量争夺

Gemini 在“量”上逼近，ChatGPT 在“质”上断层

- Gemini 的用户增长很快
  - 尤其是 Nano Banana 和 Gemini 3
- Google 生态强力引流，Gemini MAU快速提升
  - MAU 已达 ChatGPT 的 **20-25%**（8月仅为10%）
  - 但 Gemini 的 DAU / MAU 只有 ～10%，远低于 ChatGPT 的 ~25%
- ChatGPT 的优势不只是“量”还有“质”
  - ChatGPT 正成为生活助手与信息获取入口

地域特征

ChatGPT 守住高价值地区，Gemini 农村包围城市

- **ChatGPT 守住高价值地区**
  - 在美、英、德等高付费能力的发达市场，ChatGPT 占据绝对统治地位，商业化根基稳固
- **Gemini 农村包围城市**
  - 在印度、巴西、越南等安卓主导的新兴市场，Gemini 渗透率极高（MAU 达 ChatGPT 1/3 以上）

6# ChatGPT vs Gemini数据洞察：用户行为

Highlights 3 **ChatGPT 已经确立了“ Personal Assistant ”心智**

- **高频打败低频：**ChatGPT DAU/MAU ~25%，单用户月均会话数 ~9.6 次，是 Gemini 的 3–4 倍
- **生活化渗透：1）**非生产力类 query 比例明显上升，2）Web & 移动端双端使用比例都在提高3）Weekday vs Weekend 的活跃差距在收窄，**周末也在用**

Web: H1 2024

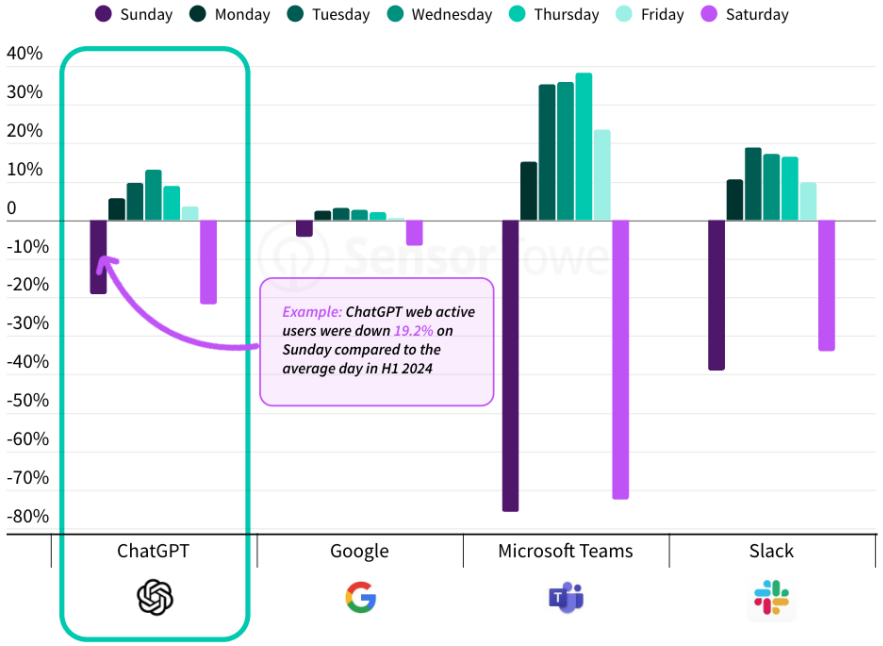

Web: H1 2025

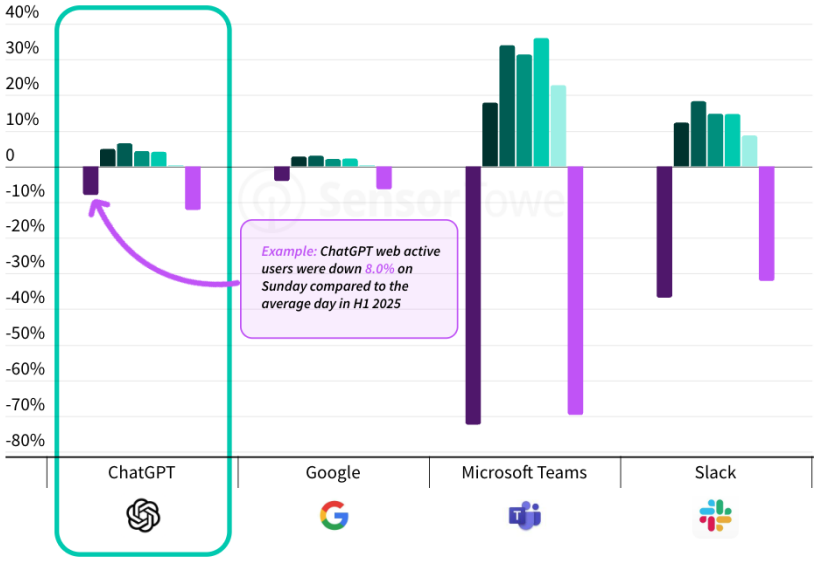

6# ChatGPT vs Gemini数据洞察：入口之争

Highlights 4 **Search vs Chatbot 15%**

- Web 流量视角：25 年 10 月 Google Search vs ChatGPT 已经从年初的 95:5 演变到约 85:15
- AI Chat 已经是**一个值得单独看待的“信息检索入口”**，不再是边缘流量

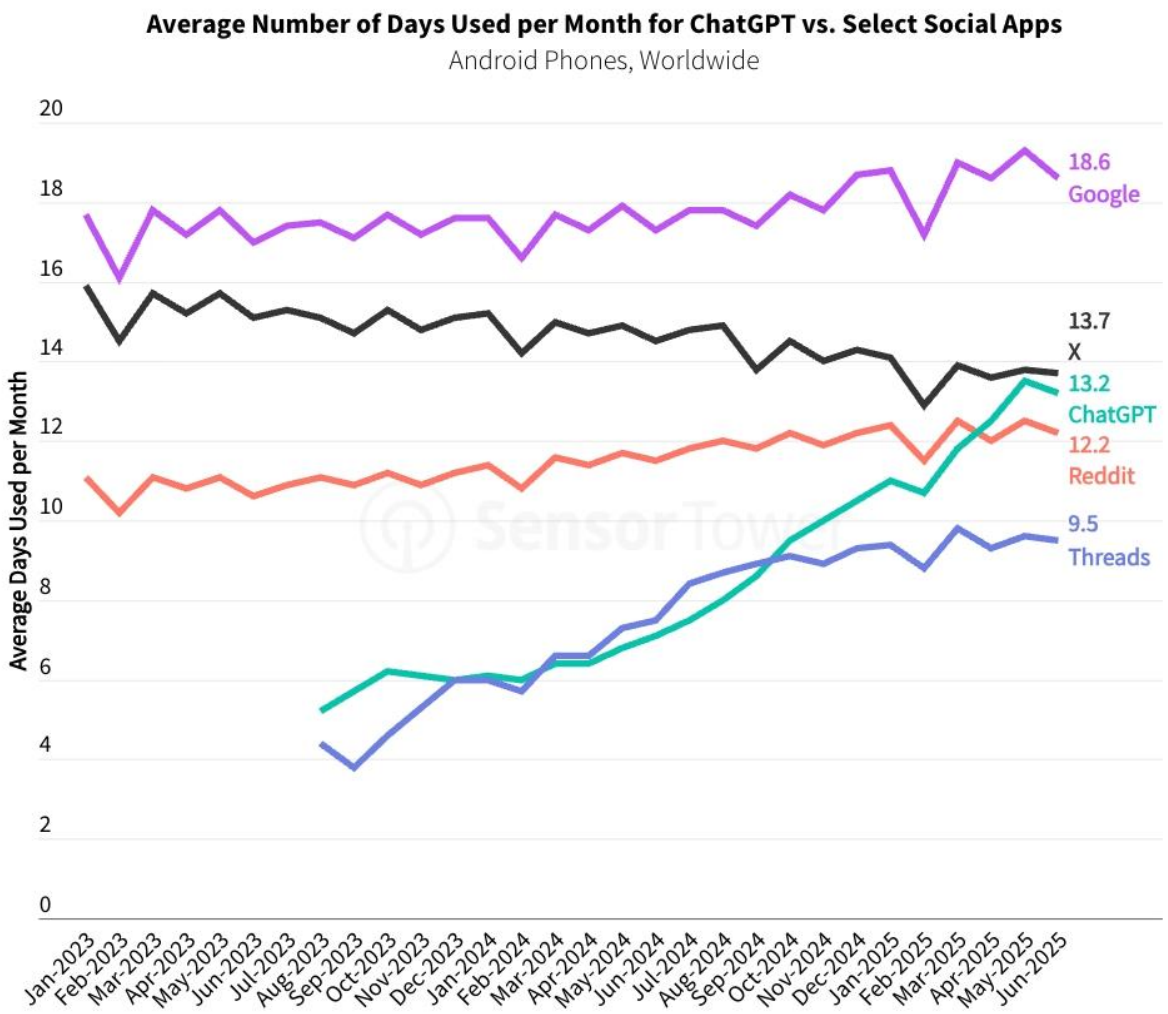

Part 03

重要技术和产品进展

拾象科技
SHIXIANG TECH

1# Next paradigm: Continual Learning

现在的 LLM 本质上是“冻结的智能”：它们在推理时表现出色，但无法从每天的交互中吸取教训

愿景：“超级实习生”需要具备“超级学习力”

- Ilya Sutskever 认为真正的 Superintelligence 不在于存储了多少知识，而在于 Sample Efficiency（样本效率）
- 一个高智商的 15 岁实习生，他刚来时可能不懂业务，但因为具备“超级学习能力”，看几个案例就能学会法律，写几个代码就能成为工程师

实现路径：技术范式转移

- **From Static to Living：** 我们正在从“训练一次用半年”的静态模型，转向“越用越聪明”的 Learn From Inference
- **Cursor 的启示：** Cursor 通过用户对代码的 accept / reject，以极短的周期（小时）更新模型，是 online RL 的开始

2# 多模态

- **Omni-in, Omni-out**
  - 无论是 Google 还是 OpenAI，技术路径已收敛
  - 视觉、音频、文本被统一 Token 化，纳入同一个自回归序列建模；这意味着模型开始有了“通感”
- 语言模型 Scaling 在多模态上的复用：自回归和 RL 都已经在多模态中
- 直接的受益者是 **Robot Learning** 和 **Multimodal Agent**
  - 机器人利用这些“合成世界”进行训练，解决了现实数据不足的问题
  - Agent 具备了“看懂 UI、读懂屏幕”的能力，为接管人类繁琐操作铺平了道路
  - 潜在有价值的 upside：新一代娱乐/游戏

从 Video 到 World Model

Sora2 AI　Veo3 AI	Google DeepMind　Genie 3
解决了物理一致性问题，进入“生产力可用”阶段	关键信号，是“通用世界模型”；不仅生成视频，而是生成可交互的 3D 环境（Playable Environment）

2# 世界模型：两大技术流派与商业化路径

- **World Model 是对时间与空间的深度理解，它不只是生成视频，更能根据当前状态与动作，模拟并预测未来的世界演化**
- **2026 年将是多模态的大年，而 World Model 是连接数字大脑与物理世界的核心 Interface**

路线 A：实时交互派 (Real-time Interactive)

- 关注低延迟 (<100ms) 与可玩性；
- 目标是Unity/Unreal，从“3D 渲染”转向“神经推理”
- 落地场景： Video-native games、虚拟人、XR

Decart

估值 $500M+；发布了首个可玩的“AI 版 Minecraft”引擎，验证了无需 Game Engine 的纯 AI 游戏生成

ODYSSEY

好莱坞级高保真重建。利用 3DGS + 电影级采集设备，连接影视工作流，主打“可编辑的真实感”

Genie 3

最强多模态巨头，和 DeepMind Robotics 深度合作

路线 B：物理仿真派 (Physics & Spatial)

- 关注物理准确性 (Physical Accuracy) 与 3D 一致性；
- 目标是成为 AI 的“训练场”
- 落地场景： 机器人导航训练、自动驾驶极端场景模拟（Sim-to-Real）

World Labs

李飞飞团队，提出 LWM (Large World Model)，从 2D 视频中学习隐式 3D 结构，致力于解决 Spatial Intelligence

general intuition

利用海量游戏数据（Medal 衍生）的“Action-State”闭环数据训练 Agent 的直觉，而非生成给人看的视频

NVIDIA Cosmos

平台型打法，内置物理引擎 Guardrails，保障生成的物理合理性

3# 重要模型进展 Update

Foundation Model **发布时间：2025.11.18**

- **能力对标**
  - 综合能力全面追平 GPT-5 级别，但在 Coding 和复杂推理（Deep Think）上展现出极强的竞争力
- **核心壁垒，Infra 与架构优势**
  - 依托 TPU + 光交换网络，Google 成功跑通超大规模稀疏 MoE 架构
  - 这意味着他们能比对手更便宜、更快速地部署巨型模型
- Gemini 3 之后，可以认为 DeepMind + Brain 的整合、TPU/infra 的打磨已经度过磨合期

3# 重要模型进展 Update

OpenAI **Agentic Framework** **发布时间：2025.10.6**

- Apps SDK 在 MCP 之上，多做了两件事
  - 不只定义“工具调用”，还定义 **App 的 UI 组件和交互逻辑**
  - **开源**，允许同一套 App 跑在所有支持 Apps SDK 的客户端上
- 对开发者体验的改进
  - 从“写 prompt + endpoint”升级为 **“写一个完整的 AI App 逻辑 + UI”**
  - 新的分发渠道直接出现在 ChatGPT 内部的 App 列表里
- 对用户体验的改进
  - 无需打开、丝滑送到你面前的“小程序”
  - Generative UI 成为插入 Chat UI 的一个新交互形式

3# 重要模型进展 Update

ANTHROP\C　　**Claud Skills**　　**发布时间：2025.10.16**

- 把“怎么做”**封装成一个个文件夹（Skill）**
- 用户可以像安装 App 一样加载“写合同”、“修代码”等技能包

- 是 Agent App Store 的另一种雏形
- **解决了 Context Window 的限制**
- 让企业可以将复杂的业务流固化为可复用、可管理的资产

4# 模型成本整体下降

LLMflation：LLM 推理价格正在快速通缩

- **能力归一化视角（用简单的 MMLU 做标尺），每年10 倍**
- 如果用 MMLU 做统一质量指标，回溯自 GPT-3 发布以来的价格数据，3 年内成本**下降约 1,000 倍**
- 高难度能力在最近一年的成本下降速度是加快的

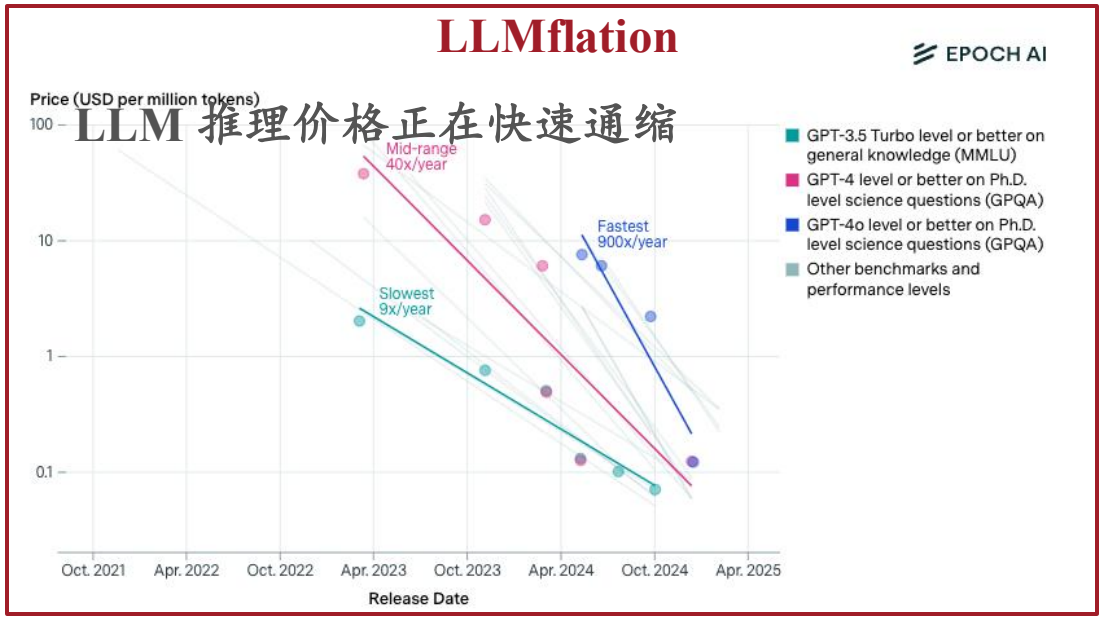

成本 10x 下降，但体感不便宜：

Agent & 多模态让每次调用变成调用链请求本身变复杂了：从“一问一答”到“一个小 workflow”：

一次任务通常包含

多轮思考（Reasoning / Thinking 模式） + 多次工具调用 + 中间状态总结

本来 1 次 API 调用就能完成的任务，现在变成 5–10 次内部调用，且输入内容变长：文件、多模态、上下文全丢进来

5#头部 AI 公司 ARR

公司	类别	成立时间	ARR（$M)
OpenAI	Foundation Model	2015	21,000
Anthropic	Foundation Model	2021	9,000
Claude code	Coding Agent	2025	1,000
Cursor	Coding Agent	2022	1,000
Surge AI	Data Labeling	2020	1,000
Mercor	Data Labeling	2023	1000
Midjourney	Creativity	2021	700
Together.AI	RL Service	2022	300
Glean	Enterprise Search	2019	200
Replit	Coding Agent	2016	253
ElevenLabs	Voice	2022	200
Perplexity	AI Search	2022	250
Lovable	Coding Agent	2023	200
OpenEvidence	Healthcare	2021	150
Synthesia	Creativity	2017	146
Fireworks AI	RL Service	2022	130
Abridge	Healthcare	2018	117
Sierra	Customer Support	2023	104

公司	类别	成立时间	ARR（$M)
Harvey	Legal	2022	150
HeyGen	Creativity	2020	100
Fal.ai	Infra	2022	100
Manus	General Agent	2023	90
Supabase	Coding Agent	2020	70
Temporal	Infra	2019	60
Higgsfield	Creativity	2024	50
Genspark	General Agent	2023	50
Chai Research	Customer	2021	40
n8n	Infra	2019	40
Bolt.new	Coding Agent	2017	40
Retell	Customer Support	2023	35
Decagon	Customer Support	2023	30
Opus Clip	Marketing	2022	20
Hippocratic AI	Healthcare	2023	20
EvenUp	Legal	2019	12
Happyrobot	Logistics	2022	10

Note: 以上数据来自公开信息或行业估算，仅供参考。

6#硅谷 Tier1 VC 都在投什么

今年下半年 Tier1 VC 的下注集中在三个方向：其一是“卖铲子”的，即 AI 时代的基础设施和开发者工具；其二深入到有钱的垂直行业，AI 能直接创造商业价值；其三，AI安全与合规相关公司高速发展，可控性日益重要

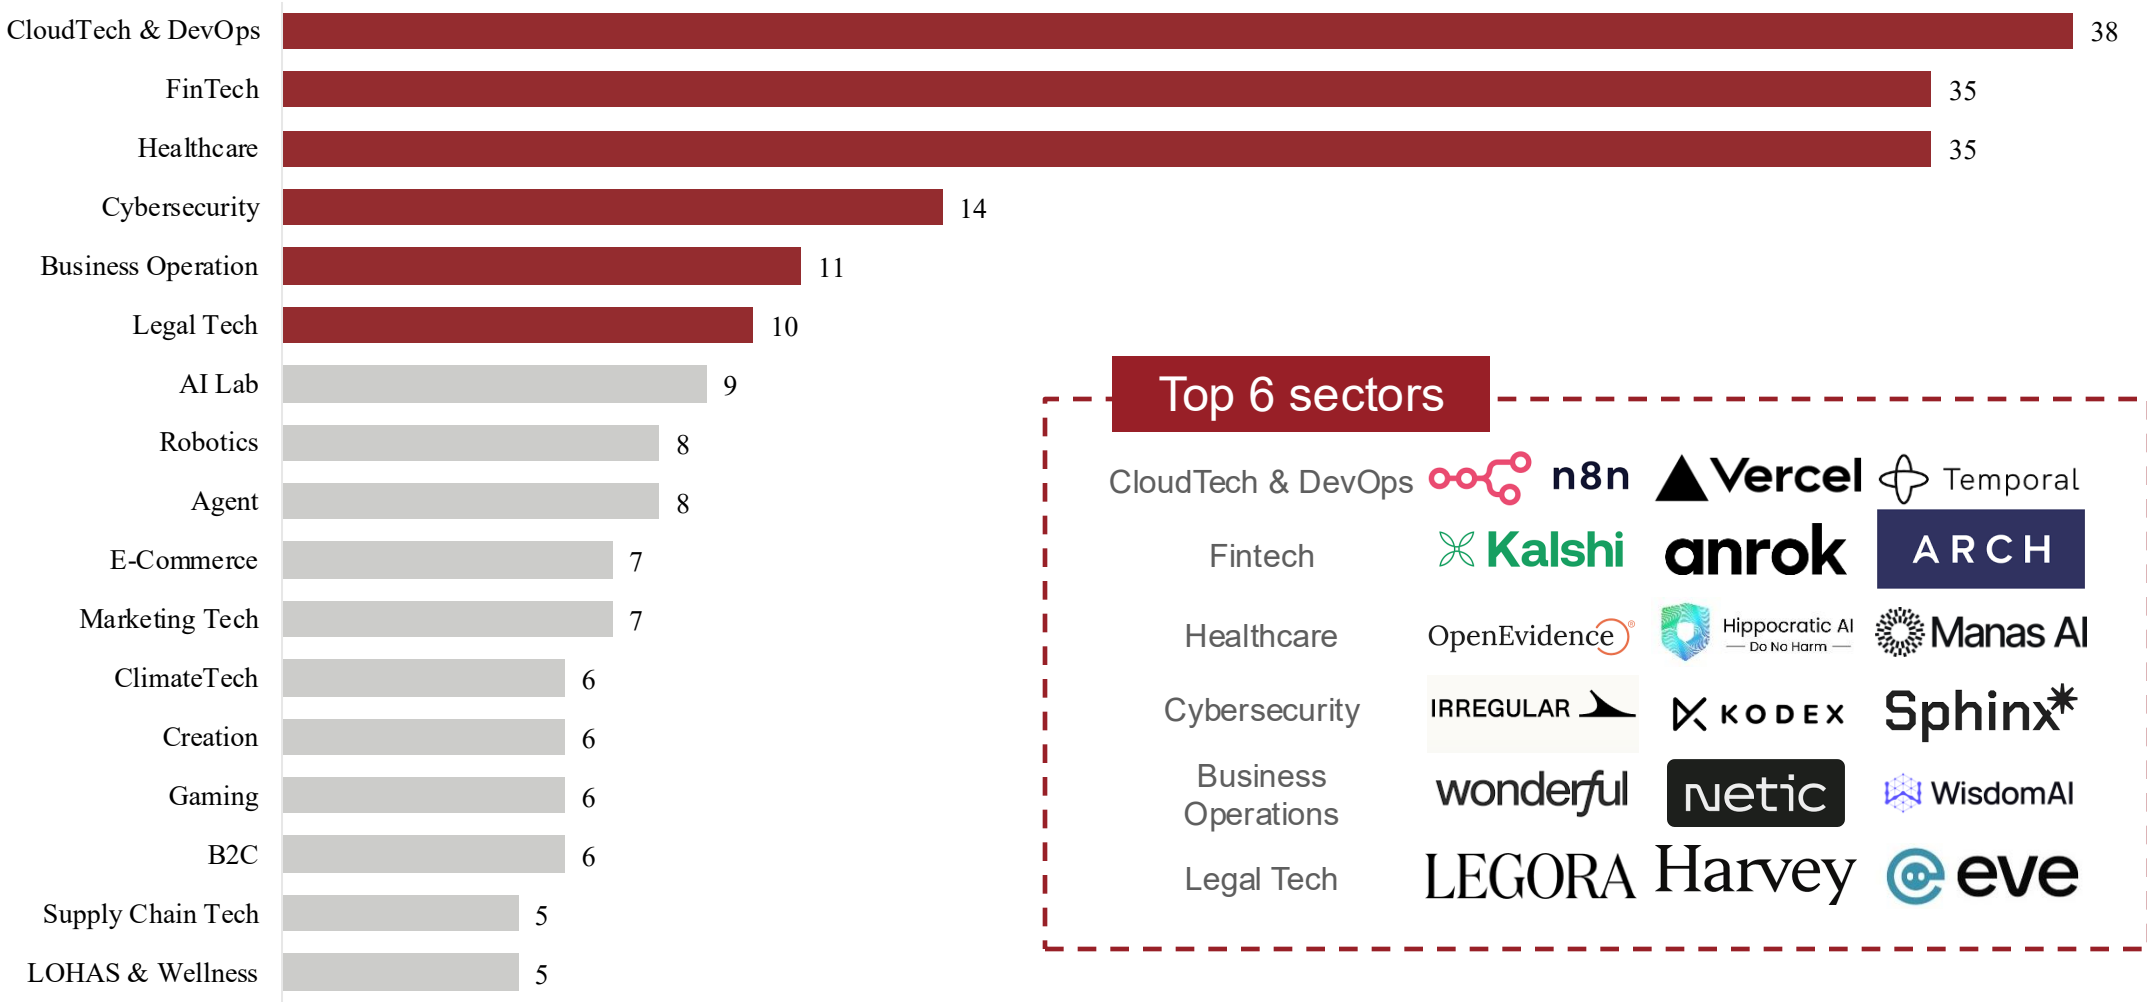

Top 6 sectors

CloudTech & DevOps	n8n, Vercel, Temporal
Fintech	Kalshi, anrok, ARCH
Healthcare	OpenEvidence, Hippocratic AI (Do No Harm), Manas AI
Cybersecurity	IRREGULAR, KODEX, Sphinx
Business Operations	wonderful, netic, WisdomAI
Legal Tech	LEGORA, Harvey, eve

Case Study# OpenEvidence：医生端高意图广告入口

把处方前 1 分钟，变成全球最大高意图医药广告入口

问诊

产品位势

覆盖 **40% 美国执业医生**，平均 13 分钟/session

从 UpToDate 的静态查资料 → **按需、结构化、秒级响应**的循证答案

75% 发生在门诊中，急诊=高频，内科=高价值

搜索

商业逻辑

医生端广告市场 **$19.8B → $29.7B**

OE 库存价值是 Doximity 的 **2-5x**

高意图场景：正在做临床决策 → 搜索 guideline/用药 → 同屏出现药物工具

第二曲线：CDSS、机构授权、教育、API

开药

最后一公里

护城河

NEJM + JAMA 独家 license，1500 万+ 同行评审文献

嵌入 Mayo、UCSF 等系统，未来可能 **替代 UpToDate**

在"临床即时决策点"捕获搜索行为，广告转化效率 **高一个数量级**

从医生“最后1米搜索”到 Pharma 的高意图流量入口 + 医疗知识基础设施

OpenEvidence	UpToDate
按需、结构化、秒级响应的循证答案	静态查资料
NEJM + JAMA 独家授权	专家团队撰写的临床总结
高意图广告 + 基础设施服务	机构/个人订阅模式

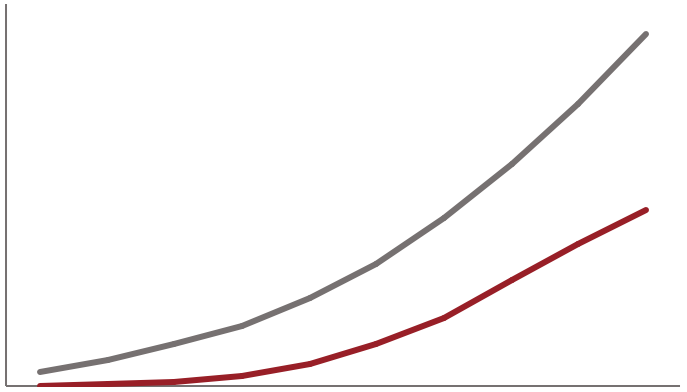

广告收入

基础设施/Licensing - 第二曲线

Case Study # Mercor：把高价值人类反馈变成 RL 时代的“数据基础设施”

从 $1M 到 $500M ARR，成为模型性能改进的核心瓶颈

核心 Insight

Evals 是新的 PRD

在从 SFT → RLHF → RLAIF 的演进里

真正的瓶颈是"怎么定义好答案"

- Mercor：真实任务环境 + 高质量评估信号
- 从学术 benchmark 转向“真实工作流 eval”：能不能写代码、过安全审查、完成多步任务
- 位置：为 RL 与 Agentic 交互提供“真反馈”，处在模型性能改进的 choke point

If model is product,
evals are the PRD & marketing

增长与规模

17 个月

$1M → $500M ARR
历史最快增长

Mag7：6/7

Mag 7 中 6 家 + 前几大 AI Lab
+ 头部应用层公司

$95-500/h

专家酬劳
扩张下仍盈利

持久性与风险

核心壁垒

- 专家网络（数万活跃）
- 与大 Lab 的耦合

趋势判断

- 人类知识未结构化
- 5-10 年仍是瓶颈

关键风险：

- OL 降低对人工反馈需求
- AI 投入周期降温 → 增长放缓

我们把 Mercor 看成“RL 的 AWS”
不押单一模型，而押“任何需要靠人类反馈提升的智能系统”

Case Study # Harvey：法律从“人力流程行业”到“模型主导知识系统”

从加人到加模型，法律行业的 AI 基础设施层

行业背景

压力上升

案件/监管压力上涨，人力基本冻结

GenAI 渗透

企业 GenAI 渗透率 ~80%
legal/risk/compliance 是成本下降最明显的部门

需求转变

“可引用、可审计的法律级 AI 工具”
从 nice-to-have → must-have

产品定位

Legal OS

不是更聪明的 ChatGPT，而是嵌入 DMS 的 **法律级 AI 决策层**

安全与幻觉控制

自研 case-law 模型 + 句级 citation，每一句都能追溯到条文/判例

workflow-native

深度接 iManage / NetDocuments，所有生成内容写回事务系统，保留完整审计轨迹

使用体验

“自己在 Westlaw 里挖答案” → 直接拿到结构化备忘录、要点与引用

工作流改写

"检索 + 归纳 + 起草" → AI 做，律师审

采用与护城河

渗透率

42-50% AmLaw 100 律所已部署或在用 Harvey

商业模式

企业级 per-seat 授权，$1,000-1,500 / 律师 / 月，随Usage上升

长期位置

- 绑定 DMS / matter system，成为“系统记录源之上的 AI 操作层”
- 与 LexisNexis 等内容巨头合作，不重造搜索引擎，而是做 AI 工作流 + 决策界面

基础设施

不只是一个工具，而是律所与企业法务未来 10 年的“AI 基础设施层”

Harvey 不只是一个工具，而是律所与企业法务未来 10 年的 "AI 基础设施层”
通过深度嵌入工作流、提供可审计的法律级决策，正在成为法律行业从"加人"到"加模型"转变的基础设施。

Part 04

How to Play AI Beta？

拾 象 科 技
SHIXIANG TECH

二级投资 Key Thesis：AI Beta

我们相信在相对长的时间框架内，AI beta 都会是科技创新的主旋律

- AI bubble：合理的警讯，但没有改变AI beta momentum本身，可以保持乐观，仍应持有AI beta basket
- AI War：是对 AI Bubble 的坚定否定：
- 客观事实出现两个势均力敌的阵营，并大概率交替领先。
- How To Play？在 AI beta basket的 分配中，两个阵营都应该有，但我们可以向暂时落后的一方稍作倾斜，针对短期叙事做逆向投资。

二级投资 Disruptive Thesis：

Disruptive Thesis：AI Beta 之外识别可能在短期会有高斜率的主题

- Proactive Agent：
- 还在早期阶段，
- 做了初步mapping，储备了一些ideas，正在耐心等待更清晰的产品落地信号。。

AI Bubble 的导火索

- 10月28日，是美股 AI 股票的阶段高点，AMD、NVDA、MSFT 都在这天不约而同阶段触顶，发生了什么？
  - OpenAI 完成了和微软的合约更新（排除了 OpenAI 股权架构对融资的最后障碍）
  - 在 OpenAI 直播中，Sam Altman 提到：已经做出 **30 GW commitments**，**$1.4T financial obligation**

如果用目前公有云常用的6年折旧摊销年限：

1.4T financial obligation = 每年烧掉 $200B +

financial obligation 是否可撤销？

- 一般**不可轻易撤销**
- 但是，OpenAI 引入**“有条件解锁”**条款，使 2028 年后的订单脱离传统 RPO 范畴，**提升了撤销或展期的灵活性**

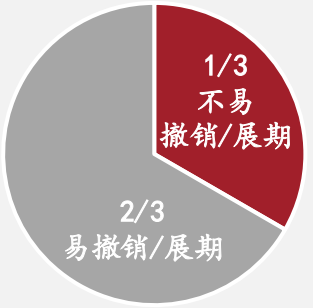

1.4T financial obligation

OpenAI 看得清的收入： ≈ $200-$300B

AI Bubble

2C

订阅制

4B WAU × 10% 订阅率 × $200 = **$80B**

- 付费用户4亿，与 Office Commercial 相当
- Sam Altman 预测2030年付费用户到2.2亿

电商 + 广告

AMZN, Tiktok level $20 ARPU × 2B WAU = **$40B**

GOOGL, META level $50 ARPU × 2B WAU = **$100B**

2B

$500B × 20% = **$100B**

若应用层用 **AI** 全部重做，**OpenAI** 收**20%**“税”

应用类软件/SaaS的 TAM 为$500B

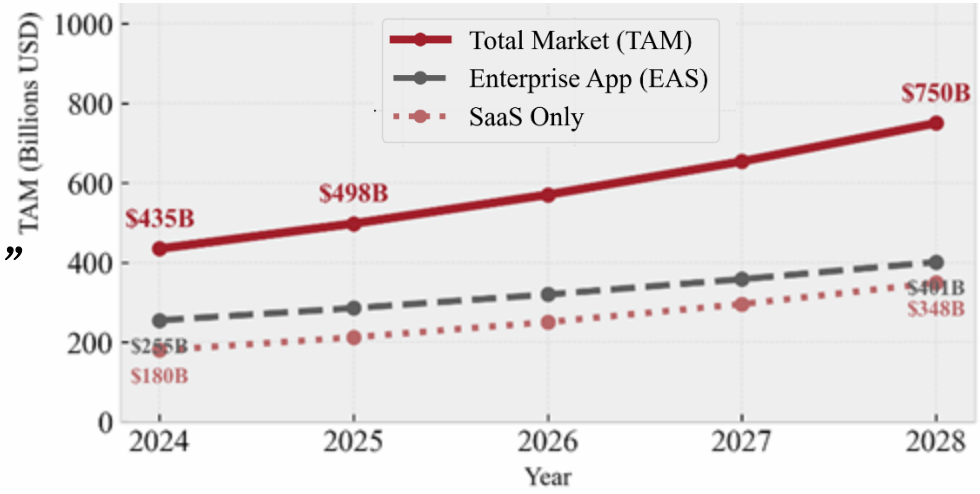

OpenAI 看不清的收入： OpenAI 的 Net New TAM

$1.4T CapEx 是 Sam Altman 在为 something never seen 下订单

新劳动力 / Agent

创造20%码农的价值

IT service TAM $1.5T × 20%自动化率 = **$300B**

创造20%白领的价值

7亿白领 × $25000 年薪 × 20%自动化率 = **$3.5T**

新设备

AI 时代的消费电子

新云

AI-centric Cloud

新娱乐

Sora

……

……

AI Bubble提出了好问题，但我们认为并不改变当前的AI Beta

AI Bubble

- **当前 Bubble 是 OpenAI Commitment 的 Bubble**
  - Commitment 在未来两年没有明显风险，三年后有展期风险
  - **估值**方面，二级市场**没有**明显 Bubble，没有用三年后的预期定价
- **AI 仍在不断带来新物种，就意味着AI beta在继续**
  - 新物种比如多模态推理、proactive agent
  - AI新玩法层出不穷，只要AI能力肉眼可见进步，永远**对 AI 带来 something never seen 保持期待**

Exhibit 7: Valuation of largest TMT stocks today vs. Tech Bubble

Dec-99			Current		
Ticker	Wgt in SPX	NTM P/E	Ticker	Wgt in SPX	NTM P/E
Microsoft Corp.	4.9%	69 x	NVIDIA Corp.	7.6%	30 x
Cisco Systems Inc.	2.8	101	Microsoft Corp.	6.9	32
Intel Corp.	2.2	32	Apple Inc.	6.5	30
Lucent Tech. Inc.	1.9	49	Alphabet Inc.	2.5	22
IBM Corp.	1.6	28	Amazon.com, Inc.	3.9	31
Time Warner Inc.	1.4	217	Meta Platforms Inc.	2.9	25
AT&T Inc.	1.4	22	Broadcom Inc.	2.6	38
AT&T Corp.	1.3	24	Tesla, Inc.	1.7	151
Oracle Corp.	1.3	90	Visa Inc.	1.1	28
WorldCom Inc.	1.2	30	Netflix, Inc.	1.0	40
Median		**41 x**	**Median**		**31 x**

Source: Goldman Sachs Global Investment Research

AI Bubble的核心启示：坚守AI beta，同时要对新物种更敏感

- 如果有新物种，我们会看到更大alpha机会
- 如果迟迟没有新物种，AI beta确实有可能接近阶段高点

AI War：硬件层之战

当需求 >> 供给，AI Beta主要矛盾，Alpha 是次要矛盾 →

无论是 GOOGL 供应链还是 NVDA 供应链，均具备极佳的投资价值

Why?

因为各玩家势均力敌

视角 1: 产品 Roadmap

摩尔定律是一个行业必须努力去达成的目标，而不是一个自然法则。

- NVDA 是行业内最努力推动摩尔定律的公司
- 若 Rubin 能力提升，能甩开TPUv8一个身位

功耗	HBM带宽
1800W → 2300W	13TB/s → 20TB/s

- TPU vs GPU 开始进入“容错率比拼”阶段

视角 2: 商业模式

- GOOGL 用好 TPU，是对其最好的背书
- NVDA 是“更纯粹的军火商”，客户更多，口袋更深
- Gemini 的广告效果是双刃剑

TPU	中立国	GPU
Google	Meta, Apple	amazon, Microsoft, TESLA

AI War：智能应用层之战

OpenAI 走的弯路只是暂时的：

- 过去两年死磕 reasoning，忽略了pre-training，但过去六个月已经把资源重新集中到 pre-training，新一代Pre-training目前on-track。
- GPT-5.2 大概率还没用上他们新改进的pre-train，明年初可能看到更明显的进步

	OpenAI	Run with maximum available reasoning effort.	Anthropic	Google
	GPT-5.2 Thinking	GPT-5.1 Thinking	Claude Opus 4.5	Gemini 3 Pro
SWE-Bench Pro Software engineering	• 55.6%	50.8%	52.0%	43.3%
GPQA Diamond Science questions (No tools)	• 92.4%	88.1%	87.0%	91.9%
CharXiv Reasoning Scientific figure questions (No tools)	• 82.1%	67.0%	—	81.4%
FrontierMath Advanced mathematics (Tier 1 – 3, Tier 4)	• 40.3% 14.6%	31.0% 12.5%	— —	37.6% • 18.8%
AIME 2025 Competition math (No tools)	• 100.0%	94.0%	92.8%	95.0%
ARC-AGI-1 Abstract reasoning	• 86.2%	72.8%	80.0%	75.0%
ARC-AGI-2 Abstract reasoning	• 52.9%	17.6%	37.6%	31.1%
GDPval Knowledge work tasks	• 70.9%	38.8% GPT-5	59.6%	53.5%

要对 Agent 爆发的拐点抱有合理耐心

- Agent：**2026年的关键不确定因素正是 Agent**
- **组织：**OpenAI 一群牛人组成的草台班子有可能孵化新物种

如果以2024年作为技术探索开端，**2026年** 也许是 Agent 产生收入的开端

- SaaS 时代，用 SaaS 重塑传统应用，再形成客户飞轮，通常需要 **3年时间**
- Agent 是全新范式，从大规模技术探索到产生客观收入，周期预计 **长于3年**

AI War：智能应用层之战

心智领先：OpenAI 在日常用户心智中仍然领先

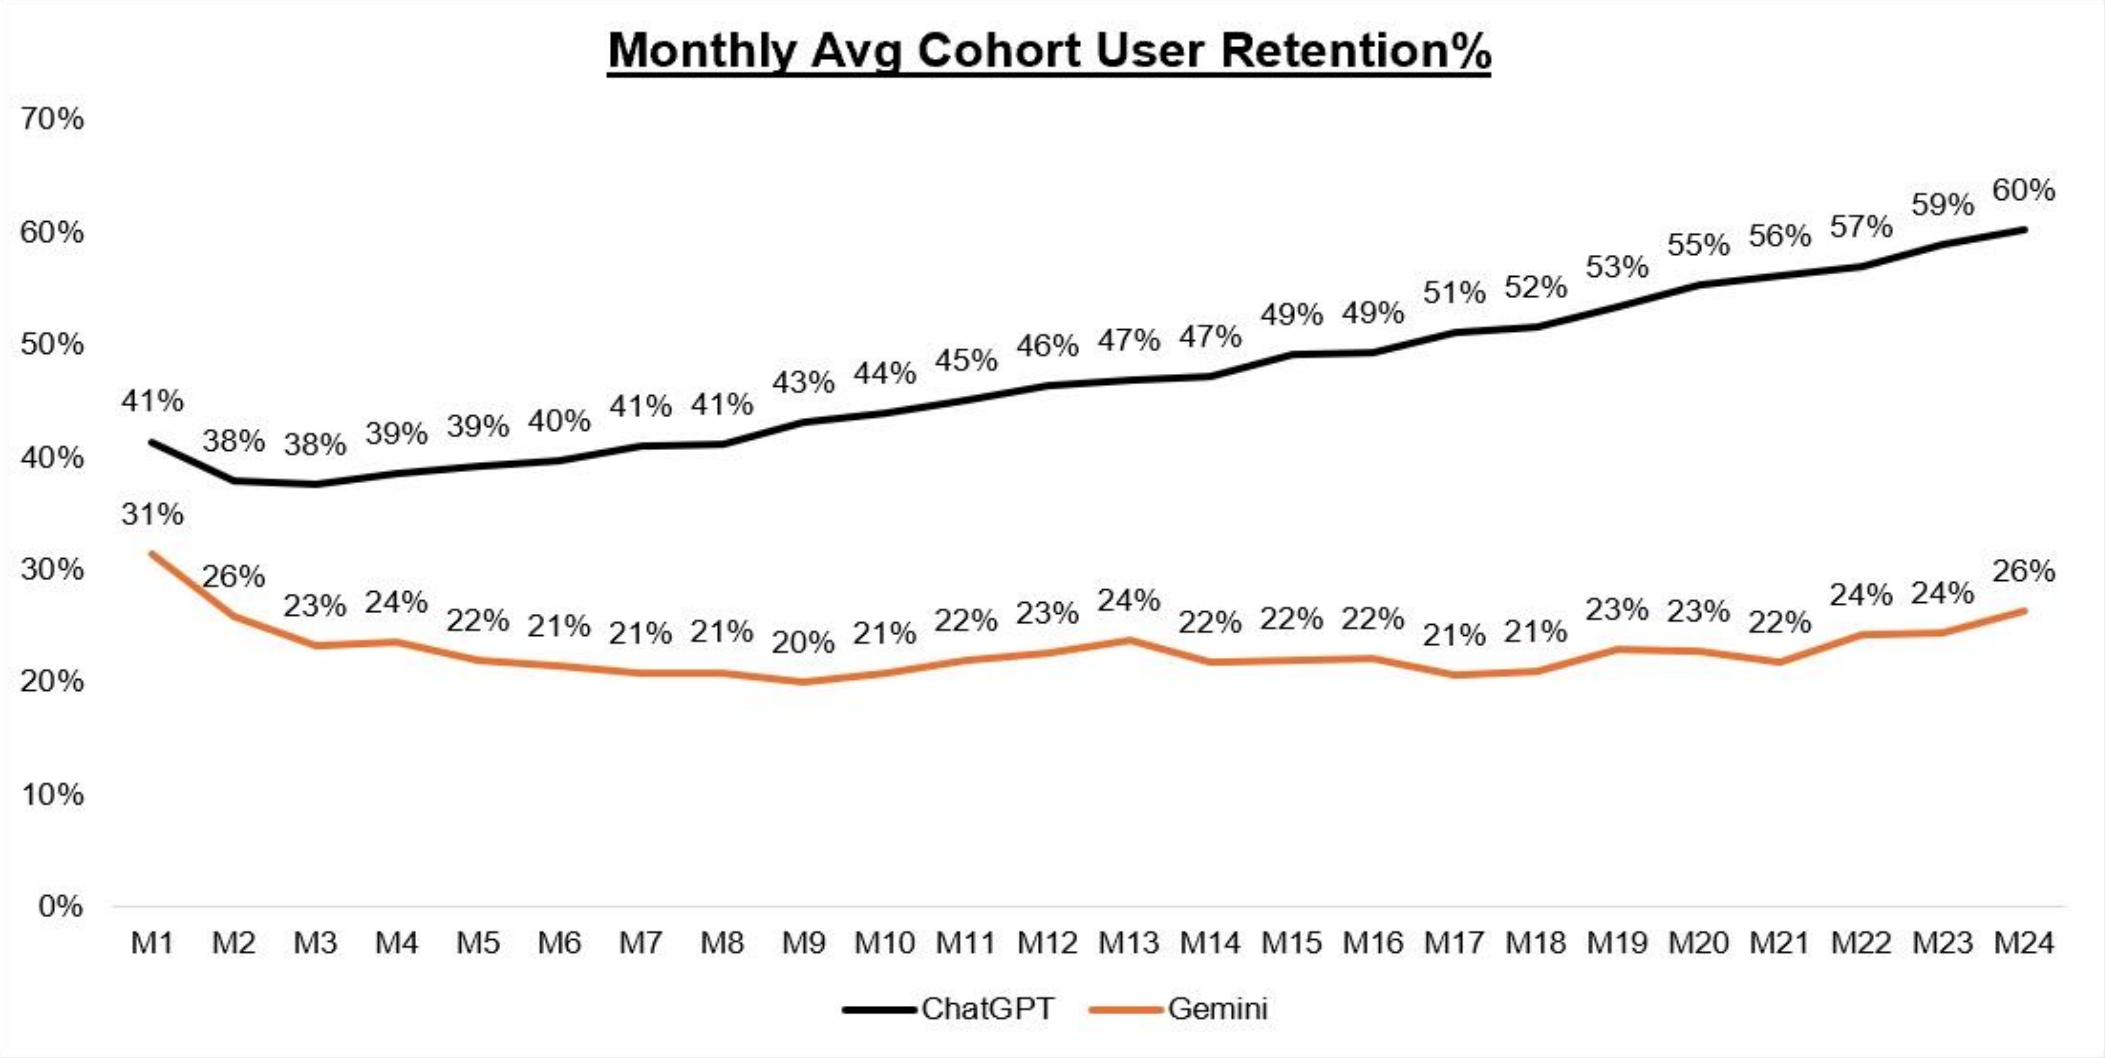

太强的 Google，会推动形成 Anti-Google 软硬同盟

拾象预测

- 如果 Gemini 领先优势扩大，将推动 NVDA 和 OpenAI 形成**更牢固的盟友**
- AI War 的两个层面会**合二为一**，会更加**势均力敌**
- 在没有架构级突破的前提下，模型将保持交替领先

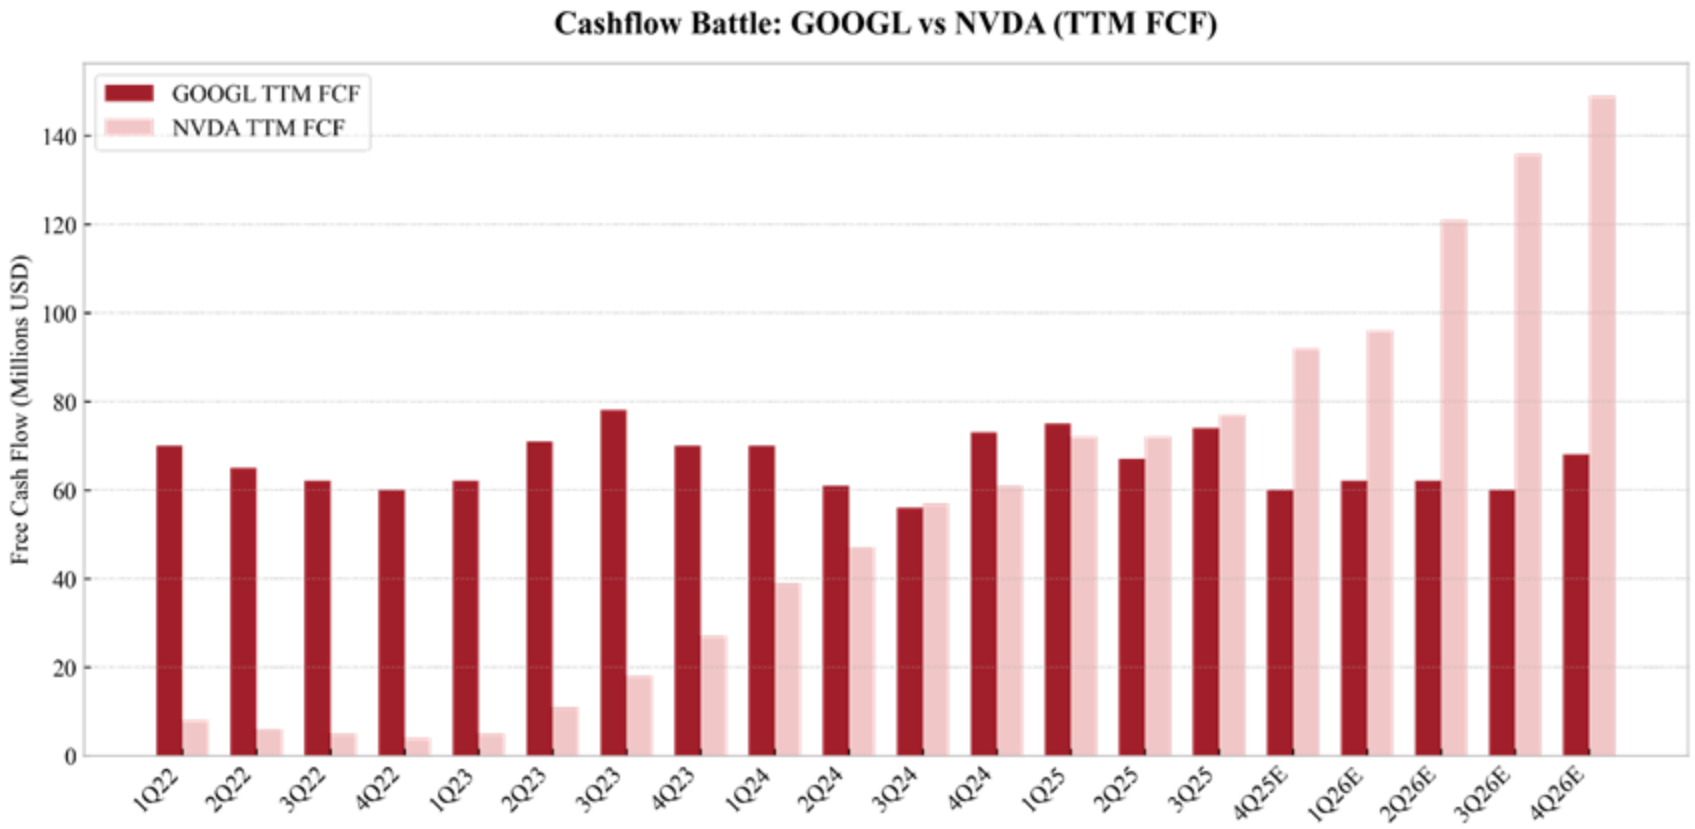

- NVDA 拿走了产业链里的现金流，是 OpenAI 现金流差的罪魁祸首。如今大敌当前，**NVDA 应该成为 OpenAI 最重要的 funding source**
- NVDA 投资 OpenAI，是用 GPU 换 OpenAI 股票，本质上是用未来贬值的商品，换有巨大 upside的资产，投资逻辑也非常合理

新物种萌芽：Agent Potential Picks

- Agent 是仍处早期萌芽阶段的新物种，拾象判断**2026年**可能非常接近落地时刻
- 保持“钓鱼”心态，**下述 ticker主要用于 ideas 储备**

应用新分发形态 MCP App / APP SDK / App UI in ChatGPT	新电商 Shopping Agent	企业定制化 Enterprise Agent	新码农 Coding Agent	新客服 Voice Agent
First mover	Shopping infra	Data infra	DevOps infra	Communication infra
INTUIT	shopify	snowflake MongoDB	JFrog	twilio
INTU 花$1亿购买 OpenAI 模型用量和 ChatGPT 的展示位 OpenAI 把 INTU 打造成标杆客户，来吸引更多“1亿美金”	和 OpenAI、GOOGL 都合作的电商后台	企业应用的经典问题： build vs buy? 何时 build 转向大规模生产？	构件 Artifactures 的集中管理系统，小而美的生意 按量计价，受益于 coding 增长	全渠道通信 API，按量计价

Q&A

拾 象 科 技
SHIXIANG TECH

Thanks

拾 象 科 技
SHIXIANG TECH